# Hacia interfaces sEMG robustas: una perspectiva Human-in-the-Loop basada en inteligencia computacional y análisis de datos

Maritza Elizabeth Albán Escobar
Universidad de Oviedo
ORCID: 0009-0008-4317-9844
Email: uo317163@uniovi.es

***Abstract*—This work presents a structured review of recent developments in surface electromyography (sEMG) interfaces, focusing on the challenge of achieving robust control under domain variability, such as muscle fatigue and electrode displacement. An exploratory analysis based on the PRISMA methodology is conducted over 15 studies (2022–2026), identifying a predominance of Deep Learning approaches that achieve high accuracy in controlled environments. Despite these advances, the analysis reveals a limited integration of data analysis and feedback mechanisms within the human-machine interaction loop, leading to systems that lack transparency and adaptability in real-world conditions. To address this gap, the study proposes a conceptual Human-in-the-Loop (HITL) model structured into three levels of interaction: end user, clinical staff, and engineers. Within this framework, computational intelligence and data analysis are treated as complementary components, where modeling enables signal processing while data interpretation supports decision-making across the system. This perspective allows robustness to be understood as a systemic property emerging from the interaction between actors, rather than solely as an algorithmic feature. The findings suggest that tailoring information to the needs of each actor in the loop can enhance system transparency, reduce cognitive burden, and improve reliability in practical applications of myoelectric interfaces.**

***Index Terms*—Surface electromyography (sEMG), Human-in-the-loop, Robustness, Computational intelligence, Data analysis, Myoelectric control, Human-machine interaction.**

## I. Introducción

Las señales mioeléctricas constituyen uno de los canales de control más naturales en el ámbito de las interfaces humano-máquina (HMI), al permitir la traducción de la actividad muscular en comandos de control. Su aplicación es especialmente relevante en el desarrollo de prótesis de extremidades superiores, donde el objetivo es restaurar la funcionalidad y la autonomía en la vida cotidiana de personas con amputación [1], [2].

En las últimas décadas, los avances en inteligencia computacional han permitido el desarrollo de modelos capaces de reconocer patrones de movimiento con altos niveles de precisión en entornos controlados. Sin embargo, trasladar este desempeño a condiciones reales de uso continúa siendo un desafío, debido a la variabilidad inherente de la señal sEMG, afectada por factores como la fatiga muscular, el desplazamiento de sensores o cambios en las condiciones de adquisición [3], [4].

En este contexto, el paradigma *Human-in-the-Loop* (HITL) ha emergido como una estrategia para mejorar la robustez de estos sistemas, proponiendo la integración activa del usuario dentro del bucle de control. A diferencia de los enfoques tradicionales de lazo cerrado, donde el sistema realiza ajustes de manera autónoma, el HITL busca que el usuario participe en el proceso de adaptación mediante el acceso a información relevante sobre el estado del sistema [1], [2].

No obstante, la literatura muestra que esta integración aún es limitada. La mayoría de los desarrollos se centran en la optimización algorítmica, mientras que el análisis de datos y los mecanismos de retroalimentación no se integran de manera efectiva en la interacción con los distintos actores del sistema. Como resultado, la información generada por los modelos permanece encapsulada, dificultando su aprovechamiento para la toma de decisiones en condiciones reales de uso.

A partir de esta problemática, el presente artículo propone un análisis estructurado de la literatura reciente en interfaces mioeléctricas, con el objetivo de identificar el grado de integración del análisis de datos y la inteligencia computacional dentro del paradigma HITL. Sobre esta base, se plantea un modelo conceptual de tres niveles de intervención —usuario, personal clínico e ingeniero— en el cual la robustez se entiende como una propiedad sistémica que emerge de la interacción entre estos actores.

Este enfoque permite reinterpretar el papel del análisis de datos no solo como una herramienta de validación, sino como un mecanismo de comunicación que facilita la adaptación y la toma de decisiones dentro del sistema. De este modo, el trabajo contribuye a la comprensión de la robustez como un fenómeno distribuido, abriendo nuevas perspectivas para el diseño de interfaces mioeléctricas más transparentes, adaptativas y funcionales en entornos reales.

## II. Metodología de Revisión Bibliográfica

La fundamentación técnica de la presente propuesta se deriva de una revisión exploratoria de la literatura científica reciente, siguiendo los lineamientos metodológicos del protocolo PRISMA [5] para la sistematización del flujo de selección. Además del proceso de identificación y filtrado de estudios, se incorporó un análisis cualitativo orientado a interpretar las

estrategias de modelado y el uso del análisis de datos en el contexto de la interacción humano-máquina.

### A. Estrategia de Búsqueda y Selección

Se realizó una búsqueda avanzada en la base de datos *IEEE Xplore*, acotando el alcance al periodo comprendido entre 2022 y 2026. Para integrar los dominios de procesamiento de señales, inteligencia computacional y factores de robustez, se empleó la cadena de búsqueda: ("sEMG" OR "EMG") AND ("machine learning" OR "data analysis" OR "feature representation") AND ("robustness" OR "variability" OR "interactive" OR "visualization").

### B. Criterios de Elegibilidad y Cribado

Para realizar una búsqueda estandarizada se aplicaron criterios de selección. Se incluyeron investigaciones originales (*journals* y *conferences*) con enfoque explícito en la mitigación de la variabilidad de dominio y representación de características. Por el contrario, se descartaron artículos de revisión (*surveys*), revisiones sistemáticas (*systematic reviews*) y aquellos cuyo enfoque no es de interés para esta investigación.

De un total de 348 registros obtenidos, el proceso de filtrado y cribado resultó en un conjunto final de 15 investigaciones relevantes. El flujo de este proceso se presenta en la Fig. 1.

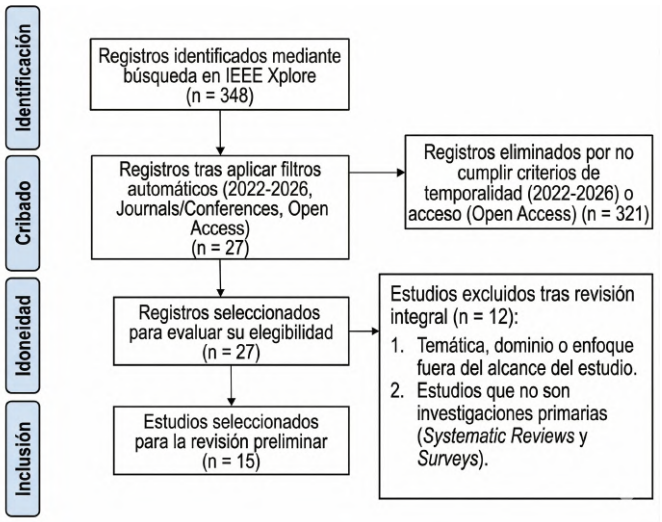



Fig. 1. Diagrama de flujo PRISMA para la selección de literatura en IEEE Xplore, detallando las fases de identificación, cribado, idoneidad e inclusión.

### C. Criterios de Análisis

Los estudios seleccionados fueron analizados mediante un enfoque cualitativo basado en la identificación de patrones en tres dimensiones principales: (I) enfoques de inteligencia computacional empleados, (II) estrategias de análisis de datos y retroalimentación, y (III) grado de integración del usuario en el bucle de control. Este proceso permitió estructurar la revisión y sirvió como base para la formulación del modelo conceptual *Human-in-the-Loop* propuesto.

## III. Análisis bibliográfico

La literatura científica reciente (2022–2026) en el ámbito de las interfaces mioeléctricas refleja un cambio de enfoque, pasando de la maximización de la precisión en entornos controlados hacia la necesidad de garantizar un comportamiento estable en condiciones de uso real. Este cambio pone de manifiesto la importancia de abordar la variabilidad propia de la señal sEMG en escenarios dinámicos, la cual constituye uno de los principales desafíos para la adopción de estos sistemas en aplicaciones cotidianas.

Como marco conceptual para este análisis, la Fig. 2 ilustra la relación entre las fuentes de variabilidad de la señal sEMG, las estrategias de procesamiento basadas en inteligencia computacional y los mecanismos de análisis e interacción. En este contexto, la robustez no se entiende únicamente como una propiedad algorítmica, sino como el resultado de la interacción entre estos componentes. El diagrama sintetiza cómo la señal, afectada por perturbaciones del entorno y del usuario, es procesada mediante modelos de aprendizaje automático y profundo, y posteriormente interpretada a través de estrategias de análisis de datos y retroalimentación.

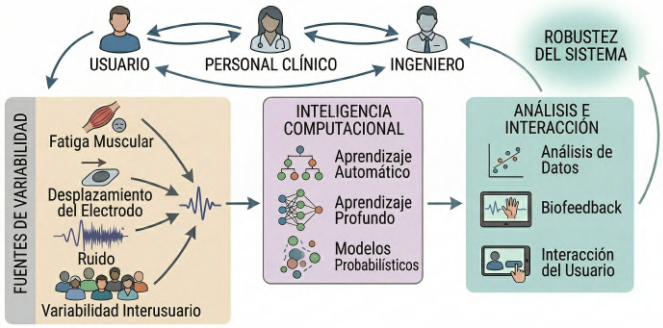



Fig. 2. Modelo conceptual de análisis de la literatura sEMG: relación entre fuentes de variabilidad, estrategias de modelado basadas en Inteligencia Computacional (ML/DL) y mecanismos de análisis e interacción con el usuario.

La Tabla I presenta una matriz de análisis del conjunto de investigaciones seleccionadas, permitiendo contrastar el dominio de aplicación de cada estudio junto con su enfoque de modelado (Eje I) y las estrategias de análisis y retroalimentación empleadas (Eje II). Este análisis permite identificar tendencias en el desarrollo de soluciones algorítmicas y mecanismos de interacción.

Sin embargo, a pesar de estos avances, la literatura evidencia limitaciones en la integración efectiva del usuario dentro del bucle de control, particularmente en la gestión de la variabilidad en condiciones reales de uso. Este vacío sugiere la necesidad de enfoques que trasciendan la optimización algorítmica y consideren la interacción humano-máquina como un componente fundamental para la robustez del sistema.

### A. Estrategias de modelado basadas en Inteligencia Computacional

El análisis de la literatura revela que la robustez del control mioeléctrico está estrechamente ligada a la capacidad de

TABLA I
MATRIZ DE ANÁLISIS DE LA LITERATURA SEMG SEGÚN ENFOQUE DE MODELADO (EJE I) Y ESTRATEGIAS DE ANÁLISIS Y RETROALIMENTACIÓN (EJE II).

| Ref. | ID | Aplicación | Eje I: Enfoque de modelado (IC) | Eje II: Estrategias de análisis y retroalimentación |
|---|---|---|---|---|
| [3] | 10138591 | Estimación movimiento (mano) | Híbrido (DL): CNN-LSTM | Validación técnica: cuantificación de error (RError) |
| [6] | 11030934 | Interacción humano-máquina | Reinforcement Learning (RL) | Retroalimentación: feedback lúdico por recompensa |
| [7] | 10904232 | Control de dedos | 1D-CNN ligera | Análisis técnico: optimización para despliegue embebido |
| [8] | 11260439 | Prótesis miembro superior | Transformers (sEMG+IMU) | Análisis algorítmico: mecanismos de atención |
| [9] | 10758785 | Gesto en muñeca | Dual-model (DL + kNN) | Ajuste automático: confianza por etiquetas auxiliares |
| [10] | 11079723 | Interfaz asistencial | Inferencia Bayesiana | Modelado lógico: incertidumbre y varianza de la señal |
| [11] | 10921689 | Manipulación diestra | GBDT y análisis no lineal | Extracción de rasgos: dinámicas motoras |
| [12] | 10456997 | Clasificación multiusuario | CNN + Transfer Learning | Ajuste automático: alineación de rasgos (CORAL) |
| [13] | 10892285 | Control gestual | Comparativa (LDA, RF, kNN) | Fusión sensorial: integración EMG+FMG |
| [14] | 9771460 | Interfaz usuario-independiente | UDA no supervisada | Ajuste automático: selección de muestras por kernel |
| [15] | 10372081 | Estimación posición mano | RPC-Net (Regresión) | Traducción de datos: sEMG a cinemática |
| [16] | 10458929 | Movimiento robusto | Unsupervised Domain Adaptation | Validación visual: mapas de puntos (t-SNE) |
| [17] | 11218962 | Control *plug-and-play* | Multi-set CCA | Ajuste automático: alineación de latentes |
| [18] | 10904858 | Co-adaptación *online* | AE + Moore-Penrose | Interacción directa: seguimiento de variedad latente |
| [4] | 10654774 | Mitigación de interferencia | Siamese AE Network (SAEN) | Ajuste automático: recuperación de datos |

los modelos para gestionar la variabilidad inherente de la señal sEMG. En este contexto, la elección del algoritmo de decisión no solo determina el rendimiento en términos de precisión, sino también la capacidad del sistema para adaptarse a perturbaciones propias de escenarios reales.

La Fig. 3 presenta una taxonomía de los 15 artículos seleccionados, clasificándolos según su enfoque de modelado predominante. Se observa que el Deep Learning constituye la estrategia más empleada ($n = 9$), seguido del Machine Learning convencional ($n = 4$), mientras que los enfoques probabilísticos y adaptativos emergen como alternativas orientadas a la gestión de la incertidumbre ($n = 2$).

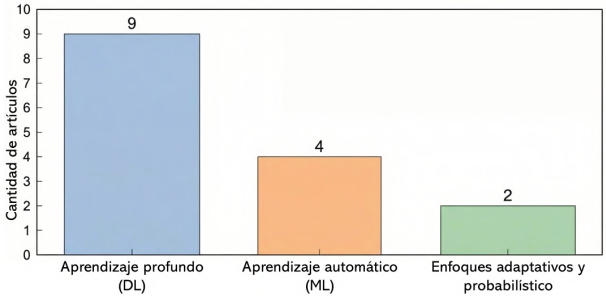



Fig. 3. Distribución de los enfoques de Inteligencia Computacional en el corpus bibliográfico seleccionado ($n = 15$), divididos en Deep Learning (DL), Machine Learning Convencional (ML) y enfoques probabilísticos.

A continuación, se desarrolla un análisis crítico de estas estrategias, evaluando su capacidad para modelar la señal sEMG en presencia de variabilidad y sus limitaciones en términos de adaptación a condiciones reales de uso.

*1) Aprendizaje Profundo (DL):* El Aprendizaje Profundo o Deep Learning se ha consolidado como el enfoque dominante en el procesamiento de señales mioeléctricas debido a su arquitectura basada en múltiples capas de procesamiento no lineal [19]. En el contexto del control mioeléctrico, su principal ventaja radica en la capacidad de aprender representaciones directamente a partir de los datos, permitiendo modelar la complejidad y variabilidad inherente de la señal sEMG. A diferencia de los métodos tradicionales, el DL se caracteriza por el aprendizaje de representaciones (Fig. 4): el algoritmo descubre automáticamente las jerarquías de características relevantes (frecuenciales, espaciales y temporales) directamente desde los datos brutos (raw data) o espectrogramas de la señal sEMG [3].

Esta capacidad de abstracción permite abordar la naturaleza no estacionaria de los músculos sin requerir un diseño manual de descriptores matemáticos, facilitando la interpretación de

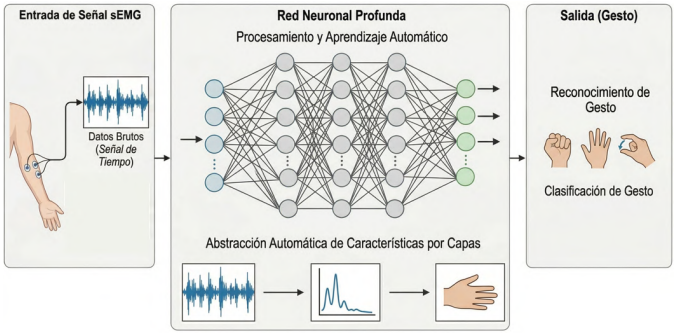



Fig. 4. Arquitectura conceptual de una red neuronal profunda para el procesamiento de sEMG, destacando la transición de datos brutos a la clasificación de gestos mediante abstracción automática.

gestos complejos en entornos dinámicos. No obstante, esta potencia analítica conlleva una alta demanda de recursos computacionales y una fuerte dependencia de la calidad y representatividad del conjunto de entrenamiento, lo que puede afectar su capacidad de generalización ante variaciones no observadas durante el aprendizaje.

Una de las vertientes más exploradas para abordar la dependencia temporal y la fatiga muscular es el uso de redes híbridas que combinan capas convolucionales con unidades de memoria recurrente, como las CNN-LSTM [3], [9]. En este esquema, las capas CNN funcionan como extractores de características espaciales entre los electrodos, mientras que las LSTM procesan la secuencia temporal del movimiento. Estas arquitecturas han demostrado altos niveles de precisión en entornos controlados, así como una capacidad destacada para capturar patrones temporales complejos. Sin embargo, su naturaleza secuencial incrementa la latencia de procesamiento y el consumo de memoria, limitando su aplicabilidad en sistemas embebidos y en escenarios de uso continuo.

Paralelamente, la evolución del DL ha incorporado modelos con mecanismos de atención, como los Transformers [8], orientados a mejorar la adaptación frente a variaciones en la señal. Estas arquitecturas permiten ponderar dinámicamente la relevancia de distintos canales de entrada, facilitando la gestión de perturbaciones asociadas a cambios de pose o artefactos de movimiento. Este enfoque se complementa con técnicas de alineación de dominio, como las redes siamesas [4] y métodos como CORAL [12], que buscan mejorar la transferencia de conocimiento entre diferentes sujetos o sesiones. A pesar de estos avances, estos modelos mantienen una alta dependencia de grandes volúmenes de datos y presentan limitaciones en términos de interpretabilidad y coste computacional.

Finalmente, para facilitar su implementación en hardware embebido, la literatura ha explorado arquitecturas optimizadas como las 1D-CNN ligeras [7] y modelos de regresión como la RPC-Net [15]. Estas propuestas priorizan la eficiencia computacional, permitiendo ejecuciones en tiempo real con baja latencia. Sin embargo, esta simplificación del modelo introduce un compromiso en la capacidad de representación, aumentando la sensibilidad del sistema a perturbaciones físicas como el desplazamiento de los electrodos (sensor shift). Este fenómeno pone de manifiesto la dificultad de equilibrar eficiencia computacional, capacidad de generalización y robustez frente a la variabilidad en condiciones reales.

*2) Aprendizaje automático convencional (ML):* A diferencia del enfoque profundo, el aprendizaje automático convencional o Machine Learning se fundamenta en la extracción dirigida de características (Fig. 5), donde el conocimiento experto define qué parámetros matemáticos deben alimentar al clasificador. En el contexto del control mioeléctrico, este enfoque ofrece una mayor interpretabilidad algorítmica, permitiendo establecer relaciones directas entre las variaciones de la señal muscular y la respuesta del sistema. Asimismo, su bajo coste computacional lo posiciona como una alternativa eficiente para aplicaciones que requieren baja latencia y ejecución en hardware con recursos limitados [19].

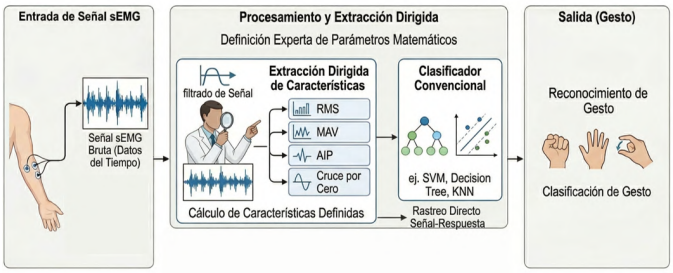



Fig. 5. Arquitectura funcional del Machine Learning convencional en sEMG. Se destaca el rol del conocimiento experto en la definición de características y las ventajas operativas en términos de interpretabilidad y eficiencia energética para sistemas embebidos.

Un pilar fundamental en esta categoría es la optimización de la manipulación mediante modelos de Bosques Aleatorios (Random Forest) y gradientes potenciados (GBDT), como se explora en [11]. Estos modelos permiten manejar datos de alta dimensionalidad con un coste computacional reducido, lo que favorece su implementación en sistemas embebidos. Sin embargo, su desempeño depende críticamente de la calidad y representatividad de las características extraídas, así como de la selección de ventanas temporales, lo que limita su capacidad para adaptarse a variaciones dinámicas de la señal.

Para contrarrestar la variabilidad inducida por factores externos, otra vertiente apuesta por la fusión de sensores y clasificadores estadísticos lineales. El estudio de [13] combina la sEMG con la mecanomiografía (FMG) mediante el Análisis de Discriminante Lineal (LDA), proyectando las características en un espacio de menor dimensión para maximizar la separación entre clases. Este enfoque mejora la estabilidad del reconocimiento bajo ciertas condiciones, como cambios en la conductividad de la piel. No obstante, esta mejora en robustez se logra a costa de una mayor complejidad física del sistema, al requerir múltiples fuentes de adquisición.

Finalmente, la adaptabilidad entre sesiones se aborda mediante técnicas de alineación estadística y adaptación de dominio, como el Análisis de Correlación Canónica (CCA) y la Adaptación de Dominio No Supervisada (UDA) [14],

[17]. Estas estrategias buscan compensar la variabilidad entre sesiones o sujetos mediante transformaciones del espacio de características. Sin embargo, al basarse principalmente en relaciones lineales, su capacidad para modelar variaciones no lineales complejas es limitada, reduciendo su eficacia en escenarios donde la señal presenta cambios estructurales más pronunciados.

En conjunto, los enfoques de ML convencional destacan por su eficiencia computacional e interpretabilidad, pero presentan limitaciones en su capacidad para modelar la complejidad y variabilidad no lineal de la señal sEMG. Esto restringe su desempeño en condiciones reales, donde las perturbaciones no siguen patrones predefinidos y requieren modelos con mayor capacidad de generalización.

*3) Enfoques adaptativos y probabilísticos:* Una vertiente emergente en la literatura busca superar las limitaciones de los clasificadores deterministas mediante la incorporación explícita de la incertidumbre y la adaptación continua (Fig. 6). A diferencia de los enfoques tradicionales, que producen decisiones discretas a partir de la señal sEMG, estos métodos permiten modelar la variabilidad de la señal como un fenómeno probabilístico, estimando la confiabilidad de las predicciones en función del contexto.

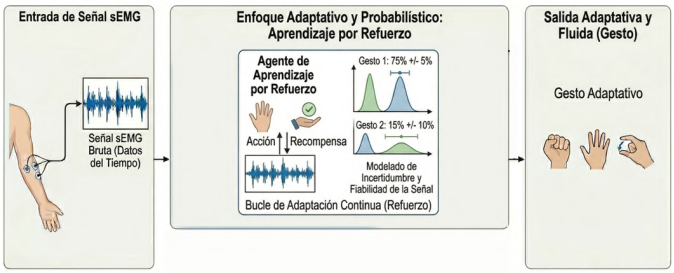



Fig. 6. Arquitectura funcional de los enfoques adaptativos y probabilísticos en sEMG. Se detalla el bucle de recompensa para la adaptación continua y el modelado de la incertidumbre gestual mediante distribuciones de probabilidad.

El uso del Aprendizaje por Refuerzo (RL) se presenta como una estrategia para la adaptación dinámica del modelo. En el estudio de [6], el algoritmo aprende una política de control óptima a través de un ciclo de estado, acción y recompensa, ajustando progresivamente sus parámetros en función del desempeño. Este enfoque permite capturar variaciones individuales en los patrones de activación muscular sin necesidad de un modelado explícito previo. Sin embargo, su principal limitación radica en el tiempo de convergencia, ya que el proceso de aprendizaje requiere múltiples iteraciones para alcanzar estabilidad, lo que puede dificultar su aplicación en escenarios donde se requiere una respuesta inmediata.

Por otro lado, la inferencia bayesiana representa un enfoque sólido para la gestión de la incertidumbre asociada a la señal sEMG [10]. Al modelar la señal como una distribución de probabilidad, este método permite actualizar continuamente la estimación del gesto en función de nueva evidencia, integrando de forma natural la variabilidad inducida por factores como el ruido, la fatiga o cambios en la conductividad de la piel. Su principal ventaja es la capacidad de cuantificar la confianza en la decisión, evitando respuestas erráticas en condiciones degradadas de la señal. No obstante, este enfoque introduce un compromiso entre precisión y velocidad de respuesta, ya que el modelado probabilístico puede incrementar la latencia del sistema.

En conjunto, estos enfoques aportan mecanismos más flexibles para modelar la variabilidad y la incertidumbre de la señal sEMG en comparación con los métodos deterministas. Sin embargo, su implementación práctica aún enfrenta limitaciones relacionadas con la eficiencia computacional, la velocidad de adaptación y la estabilidad en tiempo real, lo que evidencia la necesidad de estrategias complementarias para garantizar un comportamiento robusto en condiciones de uso reales.

### *B. Estrategias de análisis de datos y retroalimentación*

La eficacia de una interfaz mioeléctrica en condiciones de uso real no depende únicamente de la arquitectura del clasificador, sino también de la capacidad del sistema para interpretar la información extraída de la señal y devolverla de forma útil al operador. En este contexto, la literatura reciente ha explorado el uso del análisis de datos (AD) y la retroalimentación como mecanismos para abordar la variabilidad de la señal sEMG y mejorar el comportamiento del sistema en condiciones dinámicas.

A diferencia del procesamiento de señales convencional, centrado en la generación de una salida de control determinista, estas estrategias incorporan el análisis del estado interno del sistema, permitiendo identificar degradaciones en la señal y, en algunos casos, ajustar el comportamiento del modelo. Sin embargo, el grado en que esta información es utilizada dentro del bucle de control varía significativamente entre las distintas propuestas.

Como marco comparativo, la Fig. 7 sintetiza la distribución de las investigaciones seleccionadas según la finalidad del análisis de datos. Se observa una marcada tendencia hacia el uso del análisis como herramienta de ingeniería interna, existiendo un vacío significativo en el desarrollo de soluciones que integren esta información de forma continua durante la operación del sistema.

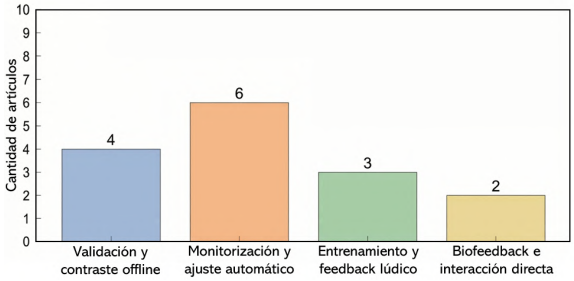



Fig. 7. Distribución de la literatura analizada según el nivel de integración del análisis de datos y la naturaleza de la retroalimentación implementada.

A partir de esta caracterización, el análisis se estructura en cuatro vertientes que describen el grado de integración del análisis de datos dentro del sistema: (I) validación y

contraste en entornos offline , (II) monitorización y ajuste automático, (III) retroalimentación en entornos controlados , y (IV) retroalimentación en tiempo real.

*1) Validación y contraste en entornos offline :* En esta categoría se agrupan las investigaciones donde el análisis de datos se emplea principalmente como una herramienta de validación estadística durante el diseño de arquitecturas (Fig. 8). El objetivo primordial no es mejorar el desempeño del sistema en tiempo real, sino proporcionar evidencia cuantitativa sobre el rendimiento de los modelos en condiciones controladas. Si bien esta vertiente permite identificar configuraciones algorítmicas más estables frente al ruido, su aplicación se limita mayoritariamente a la fase de desarrollo y evaluación.

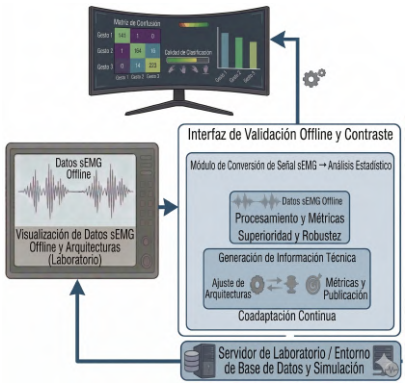



Fig. 8. Esquema de validación estadística offline. El diagrama ilustra cómo el análisis de datos se utiliza para evaluar el rendimiento del algoritmo mediante métricas y bases de datos, operando como un flujo unidireccional sin integración en el bucle de control en tiempo real.

Un uso recurrente es la visualización de espacios latentes mediante técnicas como t-SNE o métodos de interpretabilidad del modelo [3], [8]. Estas herramientas permiten verificar la separabilidad de los gestos o la relevancia de ciertos canales de entrada. Sin embargo, este nivel de análisis suele mantenerse en entornos de desarrollo y no se transfiere a la operación del sistema en tiempo real, donde únicamente se emplea la salida final del clasificador.

Asimismo, el contraste de modelos mediante métricas de dimensionalidad y latencia teórica [7], [11] permite establecer el balance entre precisión y coste computacional antes de la implementación. No obstante, este proceso genera información diagnóstica que no se incorpora durante la ejecución del sistema. Como resultado, el análisis de datos permanece desacoplado del bucle de control, limitando su contribución a la adaptación del sistema frente a variaciones presentes en condiciones reales de uso.

*2) Monitorización y ajuste automático:* Esta categoría agrupa las investigaciones que emplean el análisis de datos para dotar al sistema de capacidades de autodiagnóstico y corrección interna durante la operación (Fig. 9). A diferencia de la validación estática, en estos enfoques el algoritmo procesa métricas en tiempo real con el objetivo de compensar perturbaciones físicas como el desplazamiento de los sensores o la fatiga muscular. No obstante, se observa un patrón de diseño centrado en la ingeniería del sistema, donde la adaptación ocurre de forma autónoma, sin que la información generada sea utilizada fuera del propio modelo.

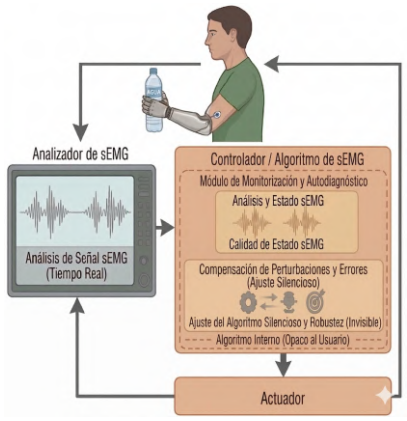



Fig. 9. Diagrama de un sistema de control con ajuste silencioso. Se ilustra cómo el autodiagnóstico y la compensación de errores ocurren internamente, sin una integración explícita de la información generada en el proceso de operación.

Un exponente claro de esta tendencia es el uso de redes siamesas y autoencoders (AE) para la detección de anomalías [4], [18]. Estos modelos calculan continuamente el error de reconstrucción de la señal sEMG; cuando este valor supera un umbral, el sistema identifica posibles fallos en la adquisición, como pérdida de contacto o desplazamiento de electrodos, y ajusta el modelo en consecuencia [3]. Este mecanismo permite mantener la continuidad del control ante perturbaciones, aunque la información diagnóstica generada permanece encapsulada dentro del sistema y no se integra en el proceso de operación más allá de la corrección automática.

Asimismo, técnicas de adaptación de dominio y alineación estadística, como las basadas en CORAL o procesos adaptativos [12], [14], [15], permiten mitigar la deriva de la señal causada por la fatiga o cambios de impedancia. El mérito técnico de estos enfoques radica en su capacidad de mantener el rendimiento del modelo a lo largo del tiempo sin requerir reentrenamientos explícitos. Sin embargo, la información derivada de estos procesos no se utiliza como un recurso activo dentro del sistema, sino únicamente como un mecanismo interno de compensación, lo que mantiene una arquitectura de control esencialmente unidireccional.

*3) Retroalimentación en entornos controlados:* Esta categoría se centra en el uso del análisis de datos para facilitar el aprendizaje del usuario durante las etapas previas a la operación diaria (Fig. 10). A diferencia de los ajustes automáticos internos, aquí la información se traduce en estímulos directos —generalmente visuales— dentro de entornos controlados como videojuegos o realidad virtual. El objetivo es que el sujeto reciba una retroalimentación inmediata sobre la calidad de su señal muscular, permitiéndole ajustar su postura o intensidad de contracción mediante un proceso guiado de ensayo y error.

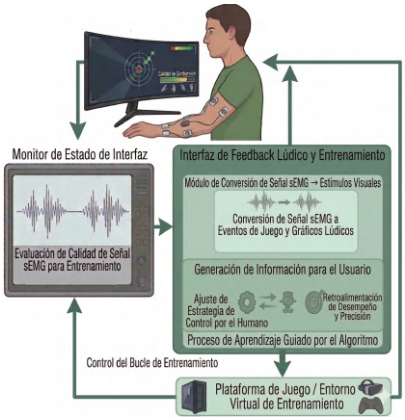



Fig. 10. Arquitectura del sistema de entrenamiento con retroalimentación en entornos lúdicos. El diagrama ilustra el flujo de información donde la señal sEMG se convierte en estímulos visuales, permitiendo al usuario ajustar su desempeño a través de un proceso guiado por el sistema.

Es importante destacar que estos procesos de entrenamiento suelen desarrollarse en entornos desacoplados de la operación real del sistema, en muchos casos sin la integración directa de la prótesis final. Esta separación introduce una discrepancia entre las condiciones de aprendizaje y las de uso cotidiano, limitando la transferencia efectiva de las habilidades adquiridas.

Un enfoque representativo es el uso de entornos de aprendizaje por refuerzo (RL) aplicados a interfaces dinámicas [6]. En estos sistemas, la retroalimentación es explícita: el algoritmo evalúa la calidad de la señal o la confianza de la clasificación y la traduce en el comportamiento de un avatar o en recompensas dentro de un entorno virtual. A través de este proceso, el usuario ajusta sus patrones de activación muscular en función del desempeño observado, mientras el modelo adapta progresivamente sus parámetros.

El principal aporte de estas propuestas es facilitar la adquisición de patrones de control más estables mediante un proceso de ajuste guiado durante el entrenamiento. Sin embargo, esta interacción se encuentra restringida a entornos controlados, ya que la adaptación ocurre principalmente durante la fase de aprendizaje y no se mantiene de forma explícita durante la operación del sistema en tiempo real.

Asimismo, se identifica el uso de métricas de alineación estadística en fases de recalibración guiada [14], [17]. Durante estas sesiones, el sistema analiza la deriva de la señal respecto a registros previos e indica si la calidad de la entrada es adecuada para iniciar la operación. Aunque este enfoque incorpora al usuario en el proceso de validación, su aplicación se limita generalmente a etapas previas al uso. Una vez finalizada la calibración, el flujo de información se interrumpe, lo que reduce la capacidad del usuario para supervisar el comportamiento del sistema durante la operación real.

*4) Retroalimentación en tiempo real:* Esta última categoría representa la vertiente menos abordada en la literatura actual, enfocándose en la integración del análisis de datos dentro del bucle de control durante la operación cotidiana del usuario. A diferencia de los entornos controlados, aquí el análisis se incorpora de forma persistente en la interfaz, transformando métricas de confianza y estado físico en información perceptible durante la ejecución de tareas reales (Fig. 9).

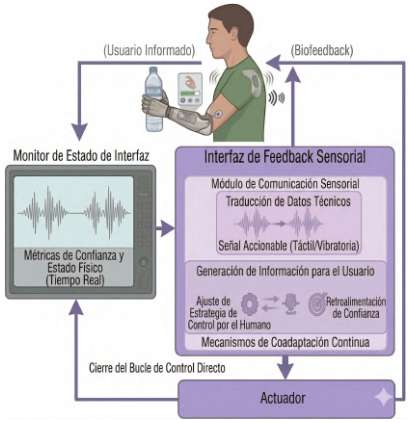



Fig. 11. Diagrama de un sistema de control con retroalimentación en tiempo real. Se ilustra la integración del análisis de datos en el bucle de control, permitiendo al usuario percibir el estado del sistema durante la ejecución de la tarea.

El objetivo de estos enfoques es permitir que el usuario disponga de información adicional sobre el estado del sistema, facilitando la adaptación de su estrategia de control frente a la variabilidad de la señal y del entorno.

Un enfoque representativo en esta línea es el uso de la inferencia bayesiana para la gestión de la incertidumbre [10]. En estos sistemas, el análisis de datos estima la probabilidad de éxito de una acción y la traduce en indicadores de confianza que reflejan la consistencia de la señal. No obstante, se identifica un desafío en la forma de presentar esta información: el uso de interfaces visuales puede incrementar la carga cognitiva del usuario, requiriendo atención adicional que interfiere con la ejecución natural de la tarea.

Asimismo, la integración de fusión sensorial con retroalimentación táctil [13] introduce el uso de actuadores vibrotáctiles en el encaje de la prótesis. Aunque este enfoque permite señalar discrepancias entre la intención del usuario y la respuesta del sistema, la literatura presenta limitaciones en la codificación de esta información. Señales vibrotáctiles genéricas carecen de la resolución necesaria para diferenciar entre distintas fuentes de error, como fatiga muscular o desplazamiento de electrodos, reduciendo su utilidad a una señal de alerta no específica.

En conjunto, estas propuestas evidencian avances hacia la integración del análisis de datos en tiempo real; sin embargo, aún presentan limitaciones en términos de interpretabilidad, carga cognitiva y riqueza informativa, lo que restringe su efectividad para apoyar al usuario en la adaptación continua durante la operación del sistema.

## IV. Modelo Human-in-the-Loop para la gestión de la robustez

A partir del análisis desarrollado en las secciones anteriores, se identifica que la robustez en interfaces mioeléctricas no

puede ser abordada únicamente desde el modelado algorítmico ni desde estrategias aisladas de interacción. En este contexto, se propone un modelo basado en el paradigma *Human-in-the-Loop* (HITL), en el cual la robustez emerge de la integración coordinada entre los distintos actores del sistema.

En la ingeniería mecatrónica, la robustez define la capacidad del sistema para mantener su funcionalidad frente a perturbaciones propias del entorno real, como la fatiga muscular o el desplazamiento de sensores. Sin embargo, la literatura analizada evidencia que estas perturbaciones son abordadas de forma fragmentada, sin un marco que articule la interacción entre el usuario, el especialista clínico y el ingeniero.

Como se ilustra en la Fig. 12, el modelo propuesto organiza la gestión de la robustez en tres niveles de intervención complementarios: el nivel operativo, centrado en el usuario; el nivel estructural, asociado al personal clínico; y el nivel algorítmico, correspondiente al ingeniero. Esta jerarquía permite distribuir la responsabilidad de la robustez como una propiedad sistémica, en lugar de delegarla exclusivamente al algoritmo.

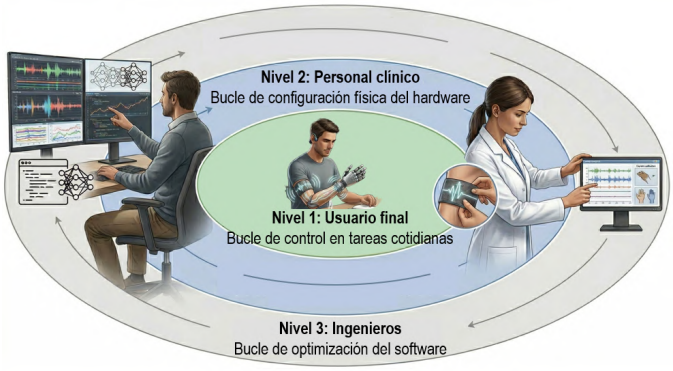



Fig. 12. Jerarquía de los tres niveles de control *Human-in-the-loop* para la gestión de la robustez sistémica.

### A. Nivel 1: Usuario final

En el nivel del usuario final, la robustez operativa se define como la capacidad del sistema hombre-máquina para mantener su funcionalidad frente a la variabilidad intrínseca de las señales sEMG. La literatura analizada identifica factores críticos que afectan esta estabilidad en un mismo individuo, como la variabilidad temporal *cross-day* [3], [12], el desplazamiento de sensores durante el movimiento [8], [16], [18] y la degradación fisiológica asociada a la fatiga [10].

Tradicionalmente, estos retos han sido abordados mediante estrategias de compensación pasiva, en las cuales el sistema emplea algoritmos avanzados para detectar anomalías y ajustar el clasificador de forma autónoma. Si bien este enfoque representa un avance significativo en la ingeniería de control, introduce una opacidad operativa en la que el usuario no dispone de información sobre el estado real de la interfaz. Como resultado, se limita su capacidad para intervenir mediante acciones físicas simples —como el reajuste del brazalete— que podrían resolver de forma más eficiente ciertas degradaciones de la señal.

Algunas investigaciones han intentado integrar al usuario dentro del bucle mediante mecanismos de retroalimentación; sin embargo, su implementación presenta limitaciones para el uso cotidiano. Los enfoques basados en entornos virtuales facilitan el aprendizaje en fases de entrenamiento [6], pero su alta demanda cognitiva restringe su aplicabilidad en tareas reales. Por otro lado, las propuestas que incorporan información diagnóstica en tiempo real suelen depender de interfaces visuales que incrementan la carga atencional y afectan la fluidez del movimiento [10]. En este contexto, la retroalimentación tiende a percibirse como un elemento adicional, en lugar de integrarse de forma natural en la interacción.

Desde la perspectiva del modelo propuesto, el potencial de este nivel radica en la capacidad del usuario para aprender a interpretar el estado del sistema y adaptar su estrategia motora. Cuando la información sobre la degradación de la señal se comunica de forma clara y no intrusiva, el usuario puede anticipar errores y realizar ajustes de manera proactiva. De este modo, la robustez deja de depender exclusivamente del algoritmo y pasa a construirse también a partir del aprendizaje del usuario.

En la Tabla II se resumen los factores descritos y su relación con posibles acciones correctivas dentro del bucle operativo.

TABLA II
FACTORES DE ROBUSTEZ INTRA-USUARIO Y ACCIONES CORRECTIVAS EN EL BUCLE OPERATIVO (HITL).

| **Factor de Robustez** | **Efecto técnico en la señal** | **Acción correctiva del usuario (HITL)** |
|---|---|---|
| Variabilidad temporal | Cambios de impedancia y recolocación de sensores. | Reajuste del brazalete o limpieza de la interfaz informada por el sistema. |
| Desplazamiento (*Shift*) | Pérdida de contacto o rotación del encaje. | Reubicación física inmediata del sensor tras notificación sutil. |
| Variabilidad dinámica | Alteración de patrones por pose o carga externa. | Modificación consciente de la postura o simplificación del gesto motor. |
| Fatiga fisiológica | Desplazamiento espectral y pérdida de potencia. | Reducción de la intensidad muscular o descanso preventivo. |

Para lograr esta integración, es necesario explorar canales de retroalimentación que operen de forma natural y con baja carga cognitiva. Alternativas como la retroalimentación térmica o el audio por conducción ósea ofrecen una percepción más orgánica y menos intrusiva, permitiendo al usuario percibir el estado del sistema sin interrumpir la ejecución de la tarea. Este enfoque permite que la robustez sea entendida como una habilidad adquirida por el usuario, complementando las capacidades del sistema algorítmico.

### B. Nivel 2: Personal clínico

En el nivel clínico, la robustez se gestiona a través del proceso de configuración física y biomecánica de la interfaz, donde el especialista —ya sea el ortoprotésico en el ajuste del dispositivo o el fisioterapeuta en el entrenamiento muscular— establece la conexión entre el cuerpo del usuario y el sistema

tecnológico. Este proceso es determinante, ya que condiciona directamente la calidad de la señal sEMG y, por tanto, el desempeño del sistema de control.

En la práctica, esta configuración suele realizarse de forma manual y depende en gran medida de la experiencia del especialista para localizar los puntos anatómicos adecuados y garantizar un contacto eléctrico estable. Los sistemas convencionales operan bajo protocolos donde el ajuste se basa en referencias empíricas, asumiendo que esta configuración inicial será suficiente para un funcionamiento adecuado del sistema.

Dentro de la literatura científica, este enfoque se manifiesta en dos vertientes principales. Por un lado, los métodos independientes del usuario [12], [17] buscan simplificar la configuración mediante modelos generalistas. Sin embargo, al no considerar las particularidades fisiológicas individuales, pueden presentar limitaciones en tareas complejas. Por otro lado, los enfoques personalizados [3], [13] emplean procesos de calibración específicos para cada sujeto, logrando una mayor precisión, pero manteniendo una fuerte dependencia de procedimientos manuales sin una validación continua de la calidad de la señal.

Desde la perspectiva del modelo propuesto, este nivel introduce el concepto de configuración informada, en el cual el especialista dispone de información objetiva sobre la calidad de la señal durante el proceso de ajuste. En lugar de depender exclusivamente de la experiencia, el sistema proporciona métricas en tiempo real que permiten validar si los sensores se encuentran en su ubicación óptima antes de finalizar la configuración.

A diferencia del usuario final (Nivel 1), que requiere información simple e integrada en la interacción, el personal clínico puede beneficiarse de herramientas de análisis más detalladas. En este contexto, el uso de visualizaciones de señal y métricas de calidad permite al especialista tomar decisiones fundamentadas para optimizar la interfaz física.

En la Tabla III se resumen los principales factores que pueden ser optimizados mediante este enfoque.

TABLA III
FACTORES DE CONFIGURACIÓN INFORMADA PARA LA OPTIMIZACIÓN DEL HARDWARE EN EL NIVEL 2.

| **Factor de ajuste** | **Impacto en la robustez** | **Acción correctiva del especialista** |
|---|---|---|
| Ubicación de electrodos | Calidad de la señal y reducción de interferencias externas. | Reubicación hacia el área muscular con mayor actividad eléctrica detectada. |
| Separación entre sensores | Reducción del *crosstalk* (traslape de señales de diferentes músculos). | Ajuste de la distancia entre electrodos para ganar claridad en los gestos. |
| Respuesta muscular | Mejora en la amplitud de la señal y el control voluntario. | Guía de ejercicios de fisioterapia para aislar movimientos y reducir la fatiga. |
| Alineación del dispositivo | Maximización de la señal según la dirección de las fibras. | Rotación del brazalete hasta encontrar el punto de mayor respuesta de los sensores. |

Este enfoque permite establecer una base física robusta desde la etapa inicial del sistema. Al optimizar la calidad de la señal en origen, se reduce la necesidad de compensaciones posteriores a nivel algorítmico, favoreciendo un sistema más estable y coherente. De este modo, la robustez no se delega exclusivamente al modelo de procesamiento, sino que se construye desde la interacción entre el especialista y el sistema.

### *C. Nivel 3: Ingenieros*

En el nivel de ingeniería, la robustez se aborda mediante el diseño de la lógica de procesamiento y la interpretación de los datos que sustentan el comportamiento del sistema. Este nivel es responsable de transformar la señal sEMG en decisiones de control, así como de definir los mecanismos que permiten adaptar el sistema a diferentes condiciones de uso.

Tradicionalmente, el desarrollo en este campo sigue una progresión que inicia en fases offline con bases de datos pregrabadas y avanza hacia evaluaciones en entornos controlados [3], [7]. En estas etapas, el rendimiento se mide mediante métricas estáticas como la precisión de clasificación, el error de regresión o la latencia. Si bien estos indicadores permiten cuantificar el desempeño, no facilitan la comprensión de las causas de los fallos, lo que limita la capacidad del ingeniero para intervenir de manera informada durante el proceso de diseño.

La literatura muestra que diversas herramientas de análisis, como visualizaciones de datos o representaciones del modelo [3], [16], se utilizan principalmente como evidencia final del rendimiento alcanzado. Sin embargo, su uso rara vez se integra de forma interactiva dentro del proceso de desarrollo, lo que mantiene al sistema como una entidad cerrada incluso para el propio diseñador.

Desde la perspectiva del modelo propuesto, este nivel se enmarca en un enfoque de diseño interactivo basado en datos, en el cual el ingeniero no solo evalúa resultados, sino que explora activamente las variables que influyen en el comportamiento del sistema. Este enfoque permite identificar relaciones entre factores como las características del usuario, las condiciones de adquisición o la configuración del hardware, generando conocimiento que trasciende las métricas tradicionales.

Bajo este esquema, el ingeniero puede interactuar con los datos de forma dinámica, agrupando muestras por categorías, ajustando ventanas temporales o analizando la relación entre diferentes señales. Este proceso transforma el desarrollo del modelo en una actividad de exploración y comprensión, donde la robustez se construye a partir del entendimiento de la variabilidad del sistema.

En la Tabla IV se resumen los principales factores que pueden ser analizados mediante este enfoque.

Este enfoque permite que el diseño algorítmico deje de ser un proceso cerrado y se convierta en una fuente de conocimiento para el sistema completo. La información generada en este nivel puede alimentar tanto la configuración clínica como la interacción del usuario, estableciendo un flujo de información coherente entre los distintos niveles del modelo. De este modo, la inteligencia computacional actúa como un

TABLA IV
FACTORES DE ANÁLISIS INTERACTIVO PARA EL DISEÑO LÓGICO DE ROBUSTEZ (NIVEL 3).

| Factor de análisis | Acción del ingeniero | Conocimiento generado |
|---|---|---|
| Perfil poblacional | Filtrado por edad, experiencia y condición médica. | Identificación de sesgos de generalización y adaptabilidad del modelo. |
| Naturaleza de señal | Correlación entre sEMG y señales complementarias. | Validación de la estabilidad del control ante ruido y cambios de pose. |
| Dinámica temporal | Variación interactiva de ventanas y solapamiento. | Optimización del compromiso entre la fluidez de respuesta y la precisión. |
| Exploración espacial | Agrupación visual por clústeres y mapas de activación. | Localización de zonas de confusión gestual y fallos de selectividad física. |

mecanismo de integración que conecta el análisis de datos con la toma de decisiones en todo el sistema.

En conjunto, los tres niveles propuestos evidencian que la robustez en interfaces mioeléctricas no es una propiedad exclusiva del modelo algorítmico, sino una característica emergente de la interacción entre los distintos actores del sistema. Mientras que el usuario contribuye mediante el aprendizaje y la adaptación motora, el personal clínico establece las condiciones físicas óptimas de adquisición, y el ingeniero diseña los mecanismos de procesamiento y análisis que articulan esta información.

Este enfoque permite entender la robustez como un proceso distribuido, donde cada nivel aporta una dimensión complementaria en la gestión de la variabilidad de la señal sEMG. En lugar de delegar la estabilidad del sistema a una única capa, el modelo *Human-in-the-Loop* propone una integración coherente de conocimiento, configuración e inteligencia computacional, favoreciendo sistemas más transparentes, adaptativos y funcionales en condiciones de uso real.

## V. CONCLUSIONES

La evolución de los sistemas mioeléctricos ha estado marcada por avances significativos en el desarrollo de algoritmos de inteligencia computacional, particularmente en el reconocimiento de patrones de movimiento con altos niveles de precisión en entornos controlados. Estos avances han consolidado una base tecnológica robusta, sustentada en modelos de aprendizaje profundo y técnicas de extracción de características.

A partir de esta base, la presente revisión identifica que, si bien el procesamiento de señales ha alcanzado un alto grado de madurez, la integración entre el sistema, el entorno y el usuario continúa siendo un desafío abierto. El análisis de la literatura evidencia que la robustez suele abordarse desde una perspectiva algorítmica, con una limitada incorporación de mecanismos que integren de manera efectiva a los distintos actores del sistema.

En este contexto, se propone un marco conceptual basado en tres niveles de intervención, donde la robustez se entiende como una propiedad distribuida que emerge de la interacción entre el usuario, el personal clínico y el ingeniero. Este enfoque permite reinterpretar los resultados de la literatura bajo una estructura que articula el flujo de información según las necesidades de cada nivel.

En el nivel del usuario, se observa que la efectividad de la retroalimentación depende de su integración natural en la tarea, lo que motiva la exploración de canales sensoriales alternativos que reduzcan la carga cognitiva. En el ámbito clínico, la robustez se relaciona con la capacidad de establecer una configuración física informada, apoyada en datos objetivos que validen la calidad de la señal. Por su parte, en el nivel de ingeniería, se identifica la necesidad de avanzar hacia enfoques de diseño interactivo que permitan comprender la variabilidad del sistema más allá de métricas estáticas.

En conjunto, estos resultados sugieren que la robustez en interfaces mioeléctricas no debe ser entendida únicamente como un problema de precisión algorítmica, sino como una propiedad que depende de la integración efectiva de información entre los distintos niveles del sistema. Bajo esta perspectiva, la inteligencia computacional y el análisis de datos actúan de forma complementaria: mientras la primera permite el procesamiento y modelado de la señal, el segundo facilita su interpretación y contextualización para la toma de decisiones dentro del bucle humano-máquina.

Esta integración permite transformar los datos en conocimiento accesible para cada actor del sistema, favoreciendo una interacción más informada y adaptativa. En consecuencia, se abren nuevas líneas de investigación orientadas al desarrollo de sistemas más transparentes, comprensibles y alineados con las condiciones reales de uso, contribuyendo a una transición más efectiva desde entornos controlados hacia aplicaciones en la vida cotidiana.

## REFERENCES


[1] P. Geethanjali, "Myoelectric control of prosthetic hands: state-of-the-art review," *Medical Devices: Evidence and Research*, pp. 247–255, 2016.

[2] W. Guo, W. Xu, Y. Zhao, X. Shi, X. Sheng, and X. Zhu, "Toward human-in-the-loop shared control for upper-limb prostheses: A systematic analysis of state-of-the-art technologies," *IEEE Transactions on Medical Robotics and Bionics*, vol. 5, no. 3, pp. 563–579, 2023.

[3] T. Bao, C. Wang, P. Yang, S. Q. Xie, Z.-Q. Zhang, and P. Zhou, "Lstm-ae for domain shift quantification in cross-day upper-limb motion estimation using surface electromyography," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 31, pp. 2570–2580, 2023.

[4] G. Gao, X. Zhang, X. Chen, and Z. Chen, "Mitigating the concurrent interference of electrode shift and loosening in myoelectric pattern recognition using siamese autoencoder network," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 32, pp. 3388–3398, 2024.

[5] D. Moher *et al.*, "Preferred reporting items for systematic reviews and meta-analyses: the prisma statement," *Annals of internal medicine*, 2009.

[6] K. Freitag, Y. Karayiannidis, J. Zbinden, and R. Laezza, "Fine-tuning myoelectric control through reinforcement learning in a game environment," *IEEE Transactions on Biomedical Engineering*, vol. 73, no. 1, pp. 168–179, 2026.

[7] V. H. Benitez, J. Pacheco, and G. Cuamea-Cruz, "Lightweight deep learning for semg-based fingers position classification and embedded system deployment," *IEEE Access*, vol. 13, pp. 38 181–38 194, 2025.

[8] D. Zholtayev, A. Riaz Khawaja, K. Ozhikenov, A. Ozhikenova, U. Shylmyrza, and B. Abdikenov, "Fast-calibration-based control for an upper-limb prosthesis," *IEEE Access*, vol. 13, pp. 202 438–202 453, 2025.

[9] Y. Liu, R. Wang, Y. Li, and Y. Wang, "A novel dual-model adaptive continuous learning strategy for wrist-semg real-time gesture recognition," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 32, pp. 4186–4196, 2024.

[10] S. Yoneda and A. Furui, "Adaptive emg pattern classification via probabilistic knowledge transfer with scale mixture-based bayesian sequential learning," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 2750–2763, 2025.

[11] Y. Xue, F. Ru, H. Du, K. Yin, P. Li, and Z. Ju, "Semg-based complex human in-hand motion recognition for dexterous robotic manipulation," *IEEE Access*, vol. 13, pp. 51 042–51 053, 2025.

[12] H. Shi, X. Jiang, C. Dai, and W. Chen, "Emg-based multi-user hand gesture classification via unsupervised transfer learning using unknown calibration gestures," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 32, pp. 1119–1131, 2024.

[13] M. Rohr, J. Haidamous, N. Schäfer, S. Schaumann, B. Latsch, M. Kupnik, and C. H. Antink, "On the benefit of fmg and emg sensor fusion for gesture recognition using cross-subject validation," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 935–944, 2025.

[14] X. Zhang, X. Zhang, L. Wu, C. Li, X. Chen, and X. Chen, "Domain adaptation with self-guided adaptive sampling strategy: Feature alignment for cross-user myoelectric pattern recognition," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 30, pp. 1374–1383, 2022.

[15] G. Rolandino, M. Gagliardi, T. Martins, G. L. Cerone, B. Andrews, and J. J. FitzGerald, "Developing rpc-net: Leveraging high-density electromyography and machine learning for improved hand position estimation," *IEEE Transactions on Biomedical Engineering*, vol. 71, no. 5, pp. 1617–1627, 2024.

[16] S. Kim and W. K. Chung, "Upper-limb position-robust motion recognition with unsupervised domain adaptation," *IEEE Access*, vol. 12, pp. 34 342–34 353, 2024.

[17] Z. Al-Mashhadani, T. Overton, D. Wu, and M. Rakhshan, "Toward plug and play myoelectric control via one-shot latent representation alignment," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 4409–4421, 2025.

[18] H. Deng, Z. Wei, X. Hu, H. Zeng, A. Song, D. Zhang, and D. Farina, "Online unsupervised adaptation of latent representation for myoelectric control during user-decoder co-adaptation," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 1026–1037, 2025.

[19] K. Sharifani and M. Amini, "Machine learning and deep learning: A review of methods and applications," *World Information Technology and Engineering Journal*, vol. 10, no. 07, pp. 3897–3904, 2023.